SAĞLIKTA YAPAY ZEKA YARIŞMASI PROJE DETAY RAPORU

GÖREV: Klinik Genomik Verilerde Yapay Zeka Tabanlı Varyant Patojenite Tahmini

Yarışma Eğitim Seviyesi: Üniversite ve Üzeri Seviyesi

Proje Adı: PatHUgen

Takım Adı: PatHUgen

Takım ID: #761197

Başvuru ID: #4882800



İÇİNDEKİLER

1. GİRİŞ 2
2. YÖNTEM 2
   2.1. Veri Kümesi, Yapısı ve Leakage Denetimi 3
   2.2. Eksik ve Aykırı Değerlerin Ele Alınması 4
   2.3. Feature Engineering ve Visualization Temelli İçgörüler 4
   2.4. Feature Selection: Null-Importance ve Hibrit ReliefF Filtresi 4
   2.5. Cross-Panel Veri Artırımı (GENEL → PAH/CFTR) 5
   2.6. Modeller ve Seçilme Gerekçeleri 5
   2.7. Hiperparametre Optimizasyonu ve Overfitting'e Karşı Önlemler 6
   2.8. Topluluk (Stacking), Kalibrasyon ve Şampiyon Seçimi 6
   2.9. Karar Eşiği ve Açıklanabilirlik 6
3. BULGULAR 7
4. SONUÇ 9
5. KAYNAKÇA 10

1. GİRİŞ

Missense varyantlar, protein dizisinde tek bir amino asit değişimine yol açan nokta mutasyonlarıdır. Bir kısmı protein işlevini bozarak patojenik etki gösterirken, önemli bir bölümü benign kalır. Bu ayrımı güvenilir biçimde yapabilmek tanı, taşıyıcılık testi, üreme danışmanlığı ve tedavi kararları için kritiktir; deneysel doğrulama ise pahalı ve yavaş olduğu için birçok varyant VUS olarak kalmaktadır. Bu çalışmada, ACMG/AMP kriterlerine [1] göre etiketlenmiş varyantların biyolojik ve hesaplamalı profillerinden patojenik/benign ayrımını tahmin eden bir model geliştirilmiştir.

Problem; genel çok-genli set (MASTER/GENEL), kalıtsal kanser (KANSER), fenilketonüri (PAH) ve kistik fibrozis (CFTR) olmak üzere dört panel üzerinden ele alınmıştır. Paneller tek bir modele zorlanmak yerine, her panel için bağımsız bir pipeline kurulmuş; ayrı öznitelik seçimi (feature selection), ayrı hyperparameter optimization, ayrı nihai model ve panele özgü threshold kullanılmıştır. Veri, asimetrik ve anonimleştirilmiş bir yapıdadır: genomik adresler ile kolon adları, dış veri tabanlarından doğrudan etiket eşleştirmesini engelleyecek biçimde gizlenmiştir. Bu nedenle tahminler, yalnızca verilen anonim profillerden (allel frekansları, in-silico skorlar, korunmuşluk ve amino asit özellikleri) üretilmiştir.

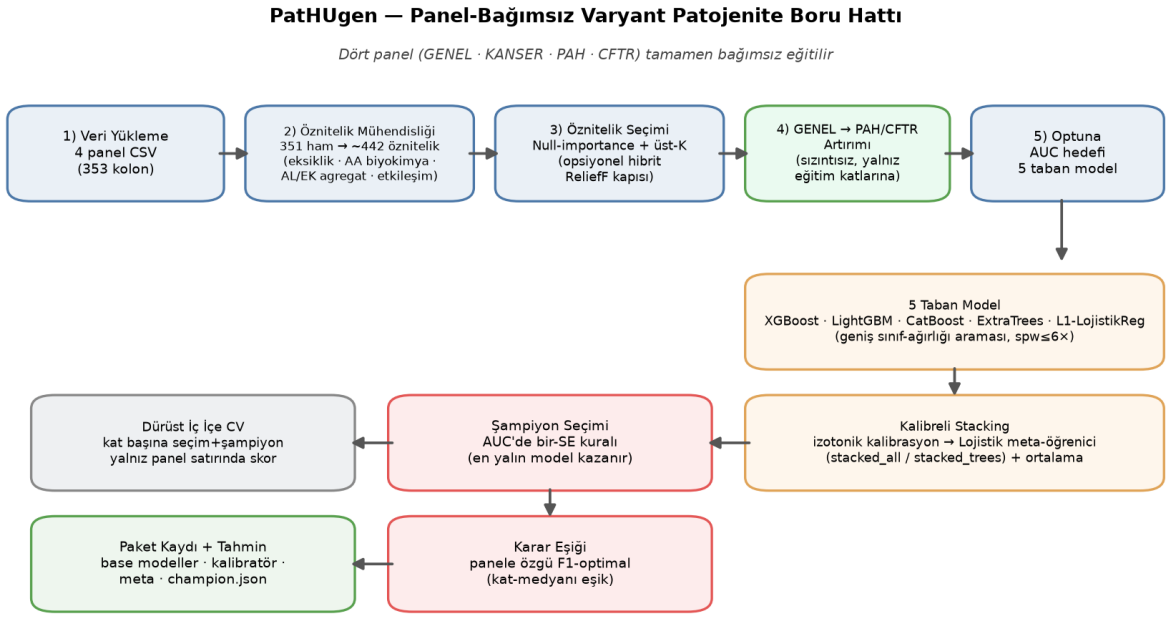
Çalışmanın en belirgin zorluğu sınıf dengesizliğidir: 3.802 varyantın %74,1'i patojeniktir; bu oran PAH'ta %83,3, CFTR'de %81,1'e çıkar. Bu tür bir dağılım, accuracy gibi ölçütleri yanıltmakta ve benign sınıfının yanlış sınıflandırılma riskini artırmaktadır. Değerlendirme aşamasında dengeli (1:1) bir test dağılımıyla karşılaşılabileceğinden, eğitim dağılımına overfitting (aşırı uyum) gösteren modellerin performansının gerileyebileceği öngörülmüştür. Bu nedenle birincil başarım ölçütü olarak ROC-AUC belirlenmiş; F1, MCC, AUPRC ve balanced F1 değerleri birlikte raporlanmıştır.

İlgili çalışmalar: Literatürdeki yöntemler çoğunlukla ClinVar [2] ve gnomAD [3] kaynaklı verilere dayanır. Jain ve ark. [4] yedi algoritma içinde en yüksek başarımı 0,88 F1 ile XGBoost'tan elde etmiştir. Quang ve ark. [5] DANN ile AUC'de %14 iyileşme; Lai ve ark. [6] LEAP ile %98'e varan AUROC; Cheng ve ark. [7] AlphaMissense ile 0,94 auROC bildirmiştir. McLaughlin ve ark. [8] XGBoost/LightGBM/TabNet tabanlı ensemble ile 0,94 üzeri AUC elde etmiş, Ruzicka ve ark. [9] XGBoost tabanlı DiagAI ile %94,9 duyarlılık raporlamıştır. Bu çalışmalar; tabular genomik veride gradient boosting ailesinin ana model grubu olarak kullanılması ve tekil modellerin calibrated ensemble yapılarıyla karşılaştırılması yönündeki yaklaşımı desteklemektedir.

2. YÖNTEM

Pipeline, veri bütünlüğü kontrolünden nihai tahmine kadar uzanan reproducible bir akış olarak kurulmuş ve dört panel için ayrı ayrı çalıştırılmıştır (Şekil 1). Sabit seed(42) kullanılmış; medyan doldurma, target encoding ve isotonic calibration gibi duruma bağlı dönüşümler yalnızca eğitim fold'unda öğrenilip doğrulama/test fold'una uygulanmıştır.

Tüm süreç tek bir Google Colab not defterinde toplanmış; nihai sonuçlar GPU hızlandırmalı tam bütçeli koşuda, panel başına 45 Optuna denemesi ve 3 tekrarlı 5-fold cross-validation ile elde edilmiştir.



Şekil 1. PatHUgen panel-bağımsız varyant patojenite pipeline'ı: veri → öznitelik mühendisliği → seçim → GENEL artırımı → 5 base model → kalibreli stacking → One-SE nihai model → panele özgü eşik.

2.1. Veri Kümesi, Yapısı ve Leakage Denetimi

Eğitim verisi dört CSV dosyasından oluşmaktadır; toplam 3.802 varyant ve 351 ham öznitelik içerir (Tablo 1). Öznitelikler dört ana grupta değerlendirilmiştir: 334 AL_ kolonu (AL_1–AL_26 allel frekansları; diğerleri in-silico skorlar ve ikili "zararlı" bayrakları), 9 EK_ kolonu (korunmuşluk/kompozit skorlar), 6 CAT_ kolonu (CAT_1/CAT_2 popülasyon kategorileri, CAT_3–CAT_5 genotip çağrıları, CAT_6 bölge maskesi) ve 2 AA_ kolonu (referans/alternatif amino asit). Etiketleme ACMG'ye göre yapılmıştır: 'Pathogenic' ve 'Likely Pathogenic' sınıfları Patojenik (1), 'Benign' ve 'Likely Benign' sınıfları Benign (0) olarak birleştirilmiştir.

Tablo 1. Eğitim veri kümesinin panel bazlı dağılımı.

Panel	Varyant	Patojenik	Benign	Patojenik oranı	Medyan eksik öznitelik
GENEL (MASTER)	2.931	2.149	782	%73,3	212
KANSER	388	268	120	%69,1	247
PAH	372	310	62	%83,3	202
CFTR	111	90	21	%81,1	37
Toplam	3.802	2.817	985	%74,1	—

Koordinat gizliliğine ek olarak, sızıntı (leakage) riski taşıyabilecek kategorik kolonlar incelenmiş; CAT_1 ve CAT_2 gibi popülasyon özniteliklerinin ve yüksek saflıklı (>%95) kategorilerin patojenite için doğrudan proxy olmadığı doğrulanarak modele eklenmiştir. Her panel, stratified 5-fold cross-validation ile ve tam bütçede 3 tekrar kullanılarak değerlendirilmiş; nested cross-validation kapsamında öznitelik seçimi ve nihai model seçimi yalnızca eğitim satırlarında gerçekleştirilmiştir.

2.2. Eksik ve Aykırı Değerlerin Ele Alınması

Satır başına ortalama ~194 öznitelik eksik durumdadır ve eksik veri (missingness) örüntüsü iki kümeye ayrılmaktadır: iyi anote edilmiş varyantlar (~0–20 eksik) ve seyrek varyantlar (~300+ eksik). XGBoost, LightGBM ve CatBoost NaN yönünü doğal biçimde öğrenebildiğinden, ağaç tabanlı modellerde eksiklik sinyal olarak korunmuştur. Bu sinyali güçlendirmek amacıyla AL/EK/CAT bazlı eksik sayıları, missingness_tier, is_skeleton, is_dense ve blok göstergeleri üretilmiştir. ExtraTrees ve L1-Logistic Regression için sayısal kolonlar eğitim fold'u medyanıyla, kategorik kolonlar target encoding ile doldurulmuştur. Aykırı değerler silinmek yerine, allele frequency kolonlarına log dönüşümü uygulanmıştır.

2.3. Öznitelik Mühendisliği (Feature Engineering) ve Görselleştirme Temelli İçgörüler

Dış veri kullanılmadan, yalnızca sağlanan anotasyonlardan türetilen 91 yeni değişkenle toplam öznitelik sayısı 442'ye çıkarılmıştır. Bunlar; eksik veri meta-öznitelikleri, amino asit biyokimyası (BLOSUM [10], Grantham, hidrofobiklik vb.), in-silico/EK agregatları ve etkileşim özniteliklerini (interaction features) kapsamaktadır.

Etkileşim öznitelikleri, EDA ve görselleştirme bulgularına göre tasarlanmıştır. Panel bazlı t-SNE grafiklerinde özellikle CFTR ve KANSER'de ayrışma; AL/EK/AA/CAT dağılımlarında ise korunmuşluk (EK) ve allele-frequency kolonlarıyla güçlü ilişki gözlenmiştir. Orange Rank analizi, missingness_tier ve ek_count değişkenlerini PAH'ta üst sıralara yerleştirmiştir. Bu nedenle eklenen missingtier_x_ekcount özniteliği, anotasyon eksiksizliği ile EK kanıt gücünü birlikte taşımış ve KANSER nihai modelinde en önemli değişken olmuştur. Benzer biçimde ek_max × Grantham, vote ratio × Grantham ve allele-log-max × EK-max etkileşimleri de eklenmiştir.

2.4. Öznitelik Seçimi: Null-Importance ve Hibrit ReliefF Filtresi

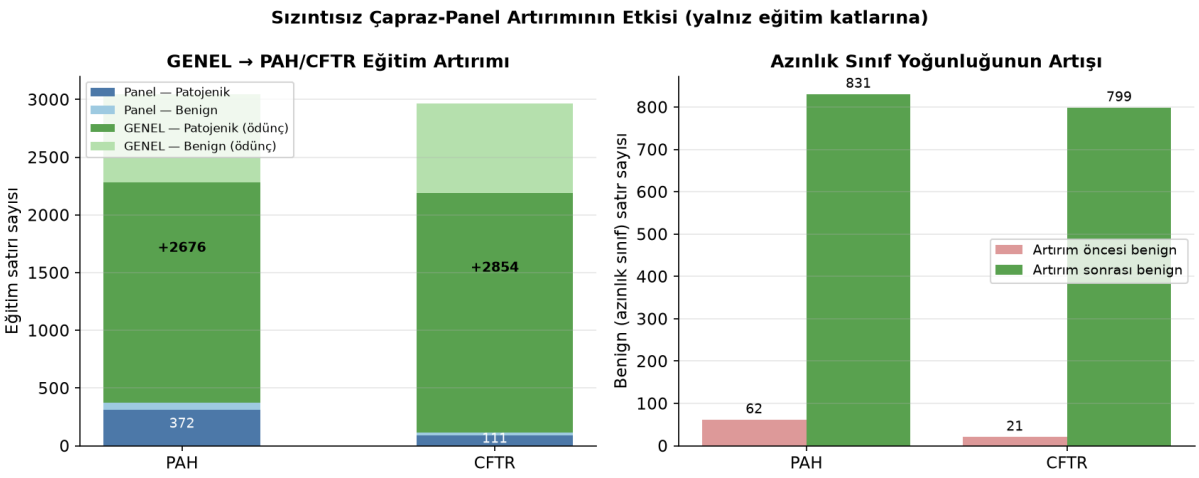
Yüksek öznitelik/örnek oranı (~442 öznitelik; küçük panellerde 111–388 satır) overfitting ve sahte önem riski doğurduğundan, öznitelik seçimi panel bazında gerçekleştirilmiştir. Birincil yöntem olarak null-importance kullanılmıştır: LightGBM gain önemleri 5 seed ortalamasıyla hesaplanmış, etiketler 40–50 kez karıştırılarak null dağılımı oluşturulmuştur. Gerçek önem, null dağılımının 95. yüzdeliğini aşıyorsa veya gain-score'a göre en iyi K içinde kalıyorsa öznitelik korunmuştur (K = min(50, max(10, n/12))). Bu filtre, panel başına 13–52 öznitelik seçmiştir (GENEL 52, KANSER 35, PAH 37, CFTR 13).

Seçilen öznitelik kümeleri biyolojik önceliklerle uyumludur. Tüm panellerde allele-frequency agregatları ve in-silico skorlar (AL) öne çıkmış; bunları EK korunmuşluk skorları, amino asit biyokimyası ve etkileşim öznitelikleri izlemiştir. CFTR'de seçim en güçlü EK/AL sinyallerinde yoğunlaşırken, GENEL panelinde daha çeşitli bir öznitelik karışımı kullanılmıştır. Özniteliklerin çoğu tek panele özgü olup, küçük bir çekirdek küme (EK_7, AL_7, ek_max, al_n_ultrarare, missingtier_x_ekcount) birden fazla panelde paylaşılmıştır. Bu bulgu, panel-bağımsız modelleme yaklaşımını desteklemektedir.

Projeye özgü ek bir katkı olarak, opsiyonel bir hibrit ReliefF filtresi geliştirilmiştir. Bu kipte null-importance kümesine ikinci bir filtre eklenmiştir: ReliefF ağırlığı negatif değilse, bilgi kazancında ilk 15 içindeyse veya kategorikse öznitelik korunmuştur. ReliefF, benzer örnekleri ayırma gücünü ölçtüğünden, gain tabanlı seçime tamamlayıcı bir bakış sunmuştur. Çok-seed denemelerinde hibrit ve yalnız-null seçimleri birbirine yakın sonuç verdiğinden, varsayılan olarak daha kararlı olan null-importance tercih edilmiştir.

2.5. Cross-Panel Veri Artırımı (GENEL → PAH/CFTR)

Küçük ve dengesiz panellerde temel sorun, benign sınıfının karar sınırını temsil edecek yeterli örneğin bulunmamasıdır (PAH'ta 62, CFTR'de 21 benign varyant). Bu sorunu leakage üretmeden hafifletmek amacıyla, GENEL (MASTER) panelinden hedefli bir veri artırımı tasarlanmıştır. GENEL paneli, Variant_ID örtüşmelerinde %100 etiket uyumu göstermektedir (PAH 255/372, KANSER 246/388, CFTR 77/111). Bu nedenle yalnızca hedef panelde bulunmayan GENEL satırları eğitim fold'larına eklenmiş; validation ve test her zaman hedef panelin kendi satırlarında tutulmuştur.



Şekil 2. Data Leakage içermeyen çapraz-panel artırımı. (Sol) PAH ve CFTR panellerine eklenen GENEL satırlarının sınıf dağılımı. (Sağ) Azınlık (benign) sınıf yoğunluğunun artışı: PAH 62→831, CFTR 21→799.

PAH için 2.676 GENEL satırı (1.907 patojenik / 769 benign), CFTR için 2.854 GENEL satırı (2.076 patojenik / 778 benign) eğitim fold'larına eklenmiştir. Bu işlem sonucunda benign eğitim örnekleri PAH'ta 62'den 831'e, CFTR'de 21'den 799'a yükselmiştir (Şekil 2). Çok-seed denemelerinde artırım, PAH'ta F1 değerini yükseltmiş, CFTR'de ROC-AUC değerini

yaklaşık 0,88'den 0,95'e taşımış; KANSER'de ise performansı düşürmüştür. Bu nedenle artırım yalnızca PAH ve CFTR panellerinde uygulanmıştır.

2.6. Modeller ve Seçilme Gerekçeleri

Anonimleştirilmiş ve yüksek eksik veri içeren tabular genomik veri için, gradient boosting decision tree ailesi doğal bir başlangıç noktası olarak seçilmiştir [4], [11]–[13]. Bu modeller eksik değerleri doğal biçimde işleyebilmekte, class imbalance'ı scale_pos_weight / auto_class_weights ile yönetebilmekte ve öznitelik önemi sağlamaktadır. Base katmanda XGBoost, LightGBM, CatBoost, ExtraTrees ve L1-Regularized Logistic Regression kullanılmıştır. Doğrusal ve aşırı-rastgele base modeller, boosting modellerinden farklı sinyalleri meta-katmana taşımıştır. Deep learning modelleri ise küçük panellerdeki overfitting riski ve yorumlanabilirlik gereksinimi nedeniyle ana çözüm olarak tercih edilmemiştir.

2.7. Hiperparametre Optimizasyonu ve Overfitting Karşıtı Önlemler

Hyperparameter optimization, her panel ve her base model için ayrı Optuna [14] (TPE) çalışmalarıyla yürütülmüştür. Objective olarak ROC-AUC kullanılmış; F1 gibi threshold ve sınıf dağılımına duyarlı metriklerin doğrudan optimize edilmesi, çoğunluk sınıfına yönelik overfitting'i artırabileceğinden tercih edilmemiştir. Arama uzayı; ağaç derinliği, learning rate, subsampling, column sampling, L1/L2 cezaları ve ağaç karmaşıklığı kısıtlarını (leaf/node kısıtları) kapsamıştır. Dengesiz panellerde class-weight çarpanı (spw_mult) aralığı log ölçeğinde 0,5–6,0'a genişletilmiş; CFTR nihai modelinin ~5,96'ya yakınsaması bu kararın gerekliliğini ortaya koymuştur.

Overfitting riski birkaç katmanda yönetilmiştir: stratified repeated 5-fold cross-validation, Optuna denemelerinde fold seed jitter, L1/L2 regularization, early stopping, 442 özniteliğin 13–52 seçilmiş özniteliğe indirgenmesi ve isotonic calibration. Nihai genelleme ölçüsü olarak nested cross-validation kullanılmıştır. OOF skorları ile nested skorlar arasındaki iyimserlik sapması (optimism bias) tüm panellerde küçük kalmış (+0,005 ile +0,034), bu da overfitting'in kontrol altında tutulduğuna işaret etmektedir.

2.8. Topluluk (Stacking), Kalibrasyon ve Nihai Model Seçimi

Beş base modelin out-of-fold (OOF) olasılıkları her fold'da isotonic regression ile kalibre edilmiş ve Logistic Regression meta-learner'a aktarılmıştır. İki stacking [16] varyantı oluşturulmuştur: stacked_trees ve stacked_all. Bunlara ek olarak mean ensemble ve beş tekil model de aday olarak değerlendirilmiştir. Nihai model seçimi, AUC üzerinde one-standard-error (One-SE) kuralıyla yapılmıştır: en yüksek AUC'nin bir bootstrap standard error sınırı içinde kalan adaylar arasından en yalın model seçilmiştir (tekil < mean < stacked_trees < stacked_all).

Dört panelin tamamında nihai model olarak tekil model belirlenmiştir: GENEL'de CatBoost, KANSER/PAH/CFTR'de XGBoost. Stacking adayları yakın skorlar üretmiş ancak

bootstrap belirsizliğini aşan kalıcı bir üstünlük göstermemiştir. One-SE kuralı bu durumda daha yalın ve dağılım kaymasına daha dayanıklı olan tekil modeli seçmiş; ensemble altyapısı ise kayıtlı bir alternatif olarak saklanmıştır.

2.9. Karar Eşiği ve Açıklanabilirlik

Class imbalance nedeniyle 0,5 threshold değerinin her panel için uygun olmayacağı öngörülmüştür. Threshold, OOF olasılıkları üzerinde 0,05–0,95 aralığında 0,005 adımla taranmış ve F1'i maksimize eden değer seçilmiştir; fold threshold'larının medyanı (fold-median threshold) alınarak tek bir bölünmeye overfitting riski azaltılmıştır. Eşikler panel karakterini yansıtmıştır: GENEL 0,28, KANSER 0,515, PAH 0,28, CFTR 0,81. Karar mekanizması, nihai modellerin kazanç tabanlı öznitelik önemi değerleri ve SHAP [15] tabanlı analizlerle değerlendirilmiş; öne çıkan sinyaller korunmuşluk, nadirlik ve biyokimyasal değişim şiddetiyle uyumlu bulunmuştur.

3. BULGULAR

Sonuçlar iki düzeyde raporlanmıştır: model seçiminde kullanılan out-of-fold (OOF) cross-validation skorları ve genelleme başarımını daha gerçekçi biçimde ölçen nested cross-validation skorları. Her metrik panel bazında hesaplanmıştır. Dört panelin ortalama nested F1 değeri 0,917 olarak elde edilmiş; OOF ve nested skorlar arasındaki iyimserlik sapması +0,005 ile +0,034 aralığında kalmıştır (Tablo 2).

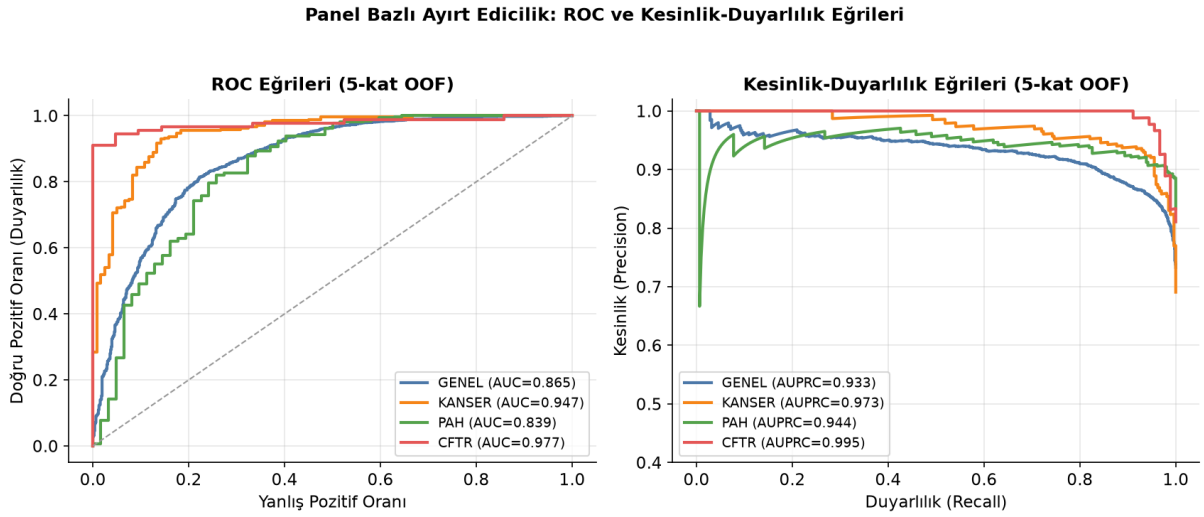
Tablo 2. Panel bazlı başarım: OOF (model seçimi) ve Nested CV (genelleme). "Dengeli F1", testin 1:1 olması hâlinde beklenen F1'dir.

Panel	Nihai Model	Öznitelik	Artırım	Eşik	OOF F1	OOF AUC	Nested F1	Nested AUC	Dengeli F1	İyimserlik Sapması
GENEL	CatBoost	52	Hayır	0,28	0,899	0,865	0,894	0,851	0,781	+0,005
KANSER	XGBoost	35	Hayır	0,515	0,933	0,947	0,915	0,924	0,852	+0,018
PAH	XGBoost	37	Evet	0,28	0,941	0,842	0,925	0,795	0,735	+0,015
CFTR	XGBoost	13	Evet	0,81	0,967	0,977	0,933	0,948	0,801	+0,034

Panel bazlı F1 değerleri, tüm örnekleri patojenik sınıfa atayan naive baseline ile karşılaştırılmıştır. Baseline'ın yüksek görünmesi (GENEL 0,846; PAH 0,909) sınıf dengesizliğinden kaynaklanmakta olup, modelin katkısı bu başlangıç noktasının üzerine eklediği kazançla ölçülmelidir. Göreli iyileşmenin en belirgin olduğu panel, baseline 0,817 değerinden OOF 0,933 değerine ulaşan (+0,116) KANSER panelidir. PAH'ta F1 yüksek görünmekle birlikte, AUC ve MCC değerleri ayrım gücünün daha temkinli yorumlanması gerektiğine işaret etmektedir.

Modellerin eşikten bağımsız ayırma gücü, ROC ve precision-recall (PR) eğrileriyle değerlendirilmiştir (Şekil 3). En güçlü paneller CFTR (AUC 0,977; AUPRC 0,995) ve KANSER (AUC 0,947; AUPRC 0,973) olmuştur. PR eğrilerinde, yüksek patojenik taban

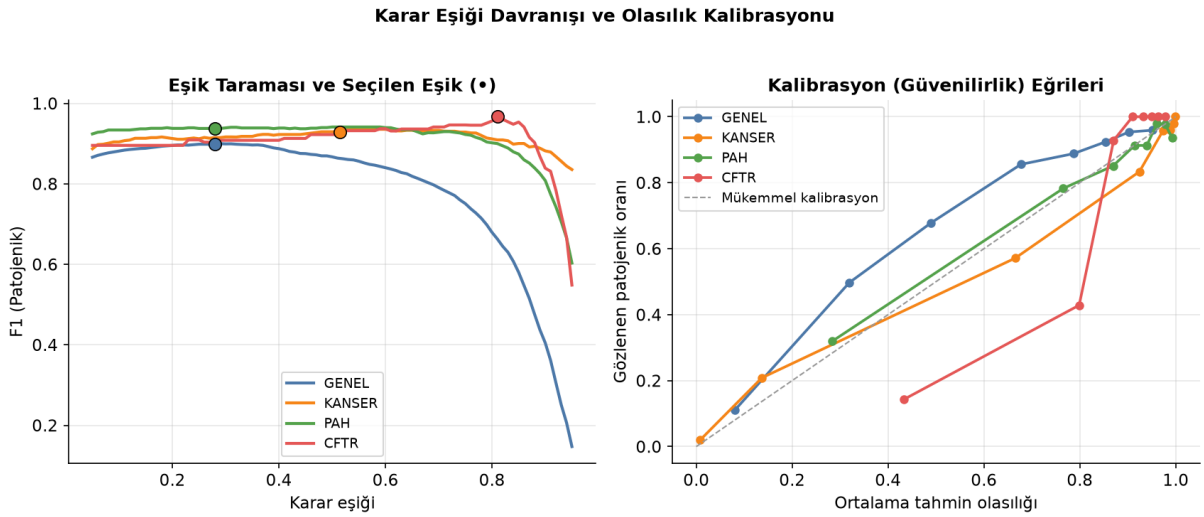
oranına rağmen modeller geniş bir recall aralığında precision değerini korumuştur. PR eğrilerindeki bu kararlılık, F1 skorunun sınıf dağılımına olan hassasiyetine karşın, modellerin gerçek ayırt edicilik performansını koruduğunu doğrulamaktadır.



Şekil 3. (Sol) Panel bazlı ROC eğrileri ve AUC. (Sağ) Kesinlik-duyarlılık eğrileri ve AUPRC (her ikisi de 5-kat OOF olasılıklarından).

ROC-AUC ve balanced F1 değerleri, sınıf dağılımına en dayanıklı panellerin KANSER ve CFTR olduğunu ortaya koymuştur. En yüksek nested AUC değerleri CFTR'de 0,948 ve KANSER'de 0,924; en düşük değer ise PAH'ta 0,795 olarak hesaplanmıştır. 1:1 test dağılımı varsayımındaki balanced F1 de benzer bir tablo sunmuş: KANSER 0,852 ve CFTR 0,801 ile daha kararlı, PAH 0,735 ile daha zorlu panel olarak ayrışmıştır.

Threshold etkisi ve probability calibration kalitesi Şekil 4'te değerlendirilmiştir. GENEL ve PAH panelleri düşük threshold değerlerinde (0,28) en iyi F1'e ulaşırken, CFTR'de en iyi denge 0,81'de oluşmuştur. Reliability curve'ler, nihai modellerin olasılıklarının genel olarak ideal köşegene yakın seyrettiğini göstermiş; CFTR'de küçük örneklem nedeniyle dalgalanma daha belirgin gözlenmiştir.

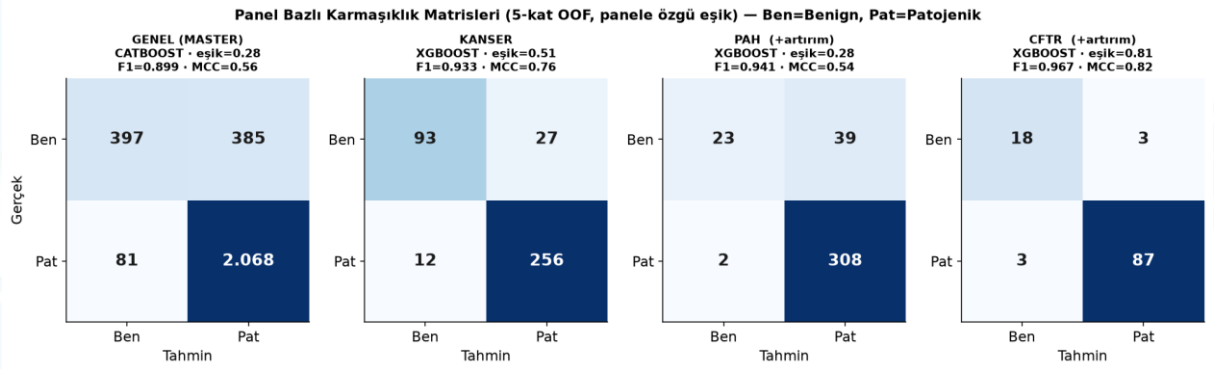


Şekil 4. (Sol) F1'in karar eşiğine göre taranması; içi dolu noktalar seçilen panele özgü eşikleri gösterir. (Sağ) Kalibrasyon (güvenilirlik) eğrileri.

Panele özgü threshold'larla elde edilen precision, recall, MCC ve AUPRC değerleri Tablo 3'te, confusion matrix sonuçları ise Şekil 5'te sunulmuştur. Tüm panellerde recall değerinin yüksek olması (0,955–0,994), patojenik varyantların kaçırılmaması önceliğiyle uyumludur. CFTR'de precision ve recall birlikte yüksek kalmıştır (0,967/0,967; MCC 0,824).

Tablo 3. Panel bazlı 5-kat OOF başarımı (panele özgü eşiklerle): kesinlik, duyarlılık, MCC ve AUPRC.

Panel	Eşik	Kesinlik	Duyarlılık	F1	MCC	AUPRC	TN	FP	FN	TP
GENEL	0,28	0,843	0,962	0,899	0,563	0,933	397	385	81	2.068
KANSER	0,515	0,905	0,955	0,933	0,760	0,973	93	27	12	256
PAH	0,28	0,888	0,994	0,941	0,543	0,944	23	39	2	308
CFTR	0,81	0,967	0,967	0,967	0,824	0,995	18	3	3	87



Şekil 5. Panel bazlı karmaşıklık matrisleri (5-kat OOF, panele özgü eşik). Ben=Benign, Pat=Patojenik.

Nihai modellerin kazanç tabanlı öznitelik önemi sıralamaları biyolojik beklentiyle uyumlu bulunmuştur. GENEL'de EK_7 ve EK ortalaması; PAH'ta AL_328, EK_7 ve BLOSUM80; CFTR'de EK-max, EK std ve al_n_ultrarare öne çıkmıştır. KANSER'de ise missingtier_x_ekcount en etkili değişken olmuş; bu durum, anotasyon eksiksizliği ile EK kanıt gücünün birlikte güçlü bir ayırt edicilik sağladığına işaret etmektedir. Genel olarak korunmuşluk (EK), popülasyon nadirliği (AL) ve amino asit ikame şiddeti (BLOSUM/Grantham) patojenitenin başlıca belirleyicileri olarak öne çıkmıştır.

4. SONUÇ

Bu çalışmada; anonimleştirilmiş ve dengesiz tabular genomik veride missense varyant patojenitesini tahmin eden, panel-bağımsız ve reproducible bir pipeline geliştirilmiştir. Her panel için ayrı null-importance öznitelik seçimi, ROC-AUC hedefli Optuna optimization, calibrated stacking ve One-SE nihai model seçimi uygulanmıştır. Ortalama nested F1 değeri 0,917 olarak elde edilmiş; bu değer panel bazında GENEL'de 0,894 ile CFTR'de 0,933 arasında değişmiştir. One-SE kuralı her panelde stacking yerine daha yalın tekil modeli seçmiştir: GENEL'de CatBoost, diğer panellerde XGBoost.

Nested cross-validation ile overfitting'den korunduğu doğrulanan bu bulgular (ortalama 0,917 F1), literatürde raporlanan XGBoost tabanlı yaklaşımların (örn. Jain ve ark. 0,88 F1 [4]) başarımlarıyla tutarlıdır. Elde edilen değerler, özellikle KANSER (0,924 AUC) ve CFTR (0,948 AUC) panellerinde mevcut ensemble yöntemlerinin (McLaughlin ve ark. >0,94 AUC [8]) genelleme kapasitesine eşdeğer, rekabetçi bir performans ortaya koymaktadır.

Çapraz-panel artırımının katkısı: En belirgin iyileştirme, GENEL panelinden PAH ve CFTR panellerine uygulanan leakage-free veri artırımıyla elde edilmiştir. Bu artırım, CFTR'nin nested ROC-AUC değerini yaklaşık 0,88'den 0,95'e taşımış; PAH'ta ise küçük panel kararlılığını artırmıştır. Kazanım, benign eğitim yoğunluğunun PAH'ta yaklaşık 13 kat, CFTR'de yaklaşık 38 kat artmasından kaynaklanmaktadır. KANSER'de artırım performansı düşürdüğünden uygulanmamış; bu durum, panel bazlı karar vermenin önemini bir kez daha ortaya koymuştur.

Güçlü ve zayıf yönler: Model; iyi anote edilmiş ve korunmuşluk sinyali belirgin varyantlarda yüksek başarım göstermiştir. CFTR, küçük örneklemine rağmen en yüksek ayrımı sağlamıştır (nested AUC 0,948; MCC 0,824). PAH ise en zorlu panel olarak kalmış (nested AUC 0,795; MCC 0,543); benign sınıfının az olması ve gri bölgeye yakınlığı nedeniyle 62 benign varyantın 39'u false positive olarak sınıflandırılmıştır. GENEL panelinde de benign specificity görece düşük kalmış olup, bu durum yüksek recall önceliğinin beklenen ödünlerinden biridir.

Yanlış pozitif/negatif: Tüm panellerde false negative sayısı düşük tutulmuş (PAH'ta 2, CFTR'de 3) ve yüksek recall elde edilmiştir. Klinik tarama bağlamında patojenik bir varyantın kaçırılmasının maliyeti, çoğu durumda gereksiz doğrulama testinden daha yüksek olduğundan, seçilen denge savunulabilir niteliktedir. Bununla birlikte GENEL ve PAH panellerindeki false positive yükü, ikincil doğrulama ihtiyacını artıran temel zayıflık olarak öne çıkmaktadır.

Değişen Test Dağılımları İçin Karar Eşiği Düzeltmesi: Olası bir veri dağılım kaymasına (distribution shift) karşı, isotonic regression ile kalibre edilmiş posterior olasılıklar üzerinden dinamik base-rate düzeltmesi planlanmıştır. Bu sayede model yeniden eğitilmeden, nihai test setindeki değişken sınıf oranlarına (prior probabilities) göre karar eşiği Bayes-optimal noktaya taşınarak yanlış pozitif yükü dinamik olarak dengelenebilecektir.

Sınırlılıklar ve final zorlukları: Başlıca riskler; threshold transferi, distribution shift, küçük panel varyansı ve kalibrasyon güncellemesidir. Eksik veri temelli öznitelikler, yeni veride farklı davranabilecek bir proxy hâline gelebilir; bu riski azaltmak amacıyla ROC-AUC hedefi, nested validation ve calibration kullanılmıştır. Özellikle CFTR'deki 21 benign satır, hata oranlarının varyansını artırabilir. Pipeline; sabit seed, kaydedilmiş model paketleri ve tek bir Colab not defteriyle reproducible durumdadır.

5. KAYNAKÇA

[1] S. Richards ve ark., "Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the ACMG and the AMP," Genetics in Medicine, c. 17, s. 5, ss. 405–424, 2015.

[2] M. J. Landrum ve ark., "ClinVar: improving access to variant interpretations and supporting evidence," Nucleic Acids Research, c. 46, s. D1, ss. D1062–D1067, 2018.

[3] K. J. Karczewski ve ark., "The mutational constraint spectrum quantified from variation in 141,456 humans," Nature, c. 581, ss. 434–443, 2020.

[4] A. Jain, G. Slabaugh, ve D. Gurdasani, "Classification of genetic variants using machine learning," arXiv:2112.05154, 2021.

[5] D. Quang, Y. Chen, ve X. Xie, "DANN: a deep learning approach for annotating the pathogenicity of genetic variants," Bioinformatics, c. 31, s. 5, ss. 761–763, 2015.

[6] C. Lai ve ark., "LEAP: Using machine learning to support variant classification in a clinical setting," Human Mutation, c. 41, s. 12, ss. 2049–2060, 2020.

[7] J. Cheng ve ark., "Accurate proteome-wide missense variant effect prediction with AlphaMissense," Science, c. 381, s. 6664, eadg7492, 2023.

[8] R. T. McLaughlin ve ark., "Fast, accurate, and racially unbiased pan-cancer tumor-only variant calling with tabular machine learning," npj Precision Oncology, c. 7, s. 4, 2023.

[9] J. Ruzicka ve ark., "Clinical evaluation of an AI system for streamlined variant interpretation in genetic testing," medRxiv, 2025.

[10] S. Henikoff ve J. G. Henikoff, "Amino acid substitution matrices from protein blocks," Proc. Natl. Acad. Sci. USA, c. 89, s. 22, ss. 10915–10919, 1992.

[11] T. Chen ve C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining, 2016, ss. 785–794.

[12] G. Ke ve ark., "LightGBM: A highly efficient gradient boosting decision tree," in Advances in Neural Information Processing Systems (NeurIPS), 2017, ss. 3146–3154.

[13] L. Prokhorenkova ve ark., "CatBoost: unbiased boosting with categorical features," in Advances in Neural Information Processing Systems (NeurIPS), 2018, ss. 6638–6648.

[14] T. Akiba, S. Sano, T. Yanase, T. Ohta, ve M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in Proc. 25th ACM SIGKDD, 2019, ss. 2623–2631.

[15] S. M. Lundberg ve S.-I. Lee, "A unified approach to interpreting model predictions," in Advances in Neural Information Processing Systems (NeurIPS), 2017, ss. 4765–4774.

[16] D. H. Wolpert, "Stacked generalization," Neural Networks, c. 5, s. 2, ss. 241–259, 1992.