TEKNOFEST 2026 · GÜNEYDOĞU SAĞLIKTA YAPAY ZEKÂ YARIŞMASI · ÜNİVERSİTE VE ÜZERİ

PatHUgen

Missense genetik varyantlarda **patojenik / benign** sınıflandırma — dört panel, dört bağımsız karar paketi, sızıntısız doğrulama.

Hasan Can Zorlu · **Mehmed Akif Arslan** · **Hüseyin Köroğlu** · **Fikret Karakuzu** · **Efe Gürdamar** | Danışman: **Assoc. Prof. Hacer Yalım Keleş** | Bilgisayar Mühendisliği, Hacettepe Üniversitesi

TAKIM ID **761197** | BAŞVURU ID **4882800** | 4 PANEL · **3.802** VARYANT · 353 KOLON | DEĞERLENDİRME: PANEL BAŞINA **F1 & MCC** ORTALAMASI | SEED **42** · DIŞ VERİ KAYNAĞI **YOK**

Dürüst çapraz doğrulamada panel ortalaması **0,92 F1** — ama asıl kanıt bu değil: naif taban modelin MCC'si **0,00** iken bizimki **0,56 – 0,79** . Model gerçekten ayrım öğreniyor.

GENEL	KANSER	PAH	CFTR
0,876	**0,924**	**0,938**	**0,952**
DÜRÜST F1	DÜRÜST F1	DÜRÜST F1	DÜRÜST F1
±0,008 · AUC 0,859	±0,030 · AUC 0,947	±0,015 · AUC 0,847	±0,029 · AUC 0,976
n = 2.931 · 38 öznitelik	n = 388 · 35 öznitelik	n = 372 · 37 öznitelik	n = 111 · 13 öznitelik

01 PROBLEM

Darboğaz sekanslama değil, *yorumlama*.

SEKANSLAMA (panel / ekzom) › ANOTASYON (frekans · korunmuşluk) › **YORUMLAMA (▲ darboğaz · elle)** › RAPOR (klinik karar)

- Nadir hastalıklı bir birey doğru tanıya ulaşana kadar ortalama **8 uzman hekimden** geçiyor; süre **~7 yıl**.
- Görev: ACMG/AMP çerçevesinde **Patojenik / Benign** ikili sınıflandırma, panel başına ayrı karar eşiği.
- **Verideki tuzak:** patojenik sınıf çoğunlukta (PAH'ta %83). Hiçbir şey öğrenmeyen naif bir model bile **0,85–0,91 F1** alır — naif taban çizgisi bu yüzden her tablomuzda yanımızda durur.

02 YÖNTEM

İki hat var; ikisini bağlayan tek bir tarife.

Kazanan tarifi *bulmak* saatler sürer, *çalıştırmak* saniyeler. Tarif koda gömülü bir sayı değil; ayrı bir yapılandırma dosyasında durur ve bir insan onaylamadan değişmez.

- **Ne denenir?** XGBoost, LightGBM, CatBoost, ExtraTrees, L1-LogReg ve izotonik kalibrasyonlu stacking; Optuna hedefi ROC-AUC.
- **Kim kazanır?** *One-SE* kuralı ayırt edilemeyen adaylar arasından en yalınını seçer — dört panelde de şampiyon **tek bir XGBoost**. **Teslim edilen sistemde stack yok.**
- **Sapma neden imkânsız?** Eğitim ve tahmin aynı öznitelik dönüşümünü çağırır; kategorik sözlük eğitimde kaydedilir, tahminde aynen kullanılır.

ARAMA HATTI · saatler — Yüzlerce kombinasyon · 5 model ailesi · panel başına bağımsız Optuna araması.

TESLİM HATTI · saniyeler — Yalnızca kazanan tarifi okur ve çalıştırır · ~1 MB paket · GPU yok, dış çağrı yok.

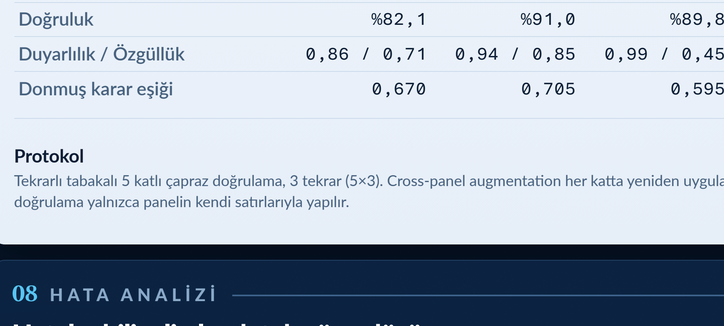
03 YEDİ ADIM · VERİDEN KALİBRE OLASILIĞA

1 **VERİ** — 4 panel · 3.802 varyant · 353 kolon
2 **ÖZNİTELİK** — durumsuz dönüşüm · 351 → 442 kolon
3 **SEÇİM** — null-importance (± ReliefF) · 441 → 13–38
4 **ARTIRIM** — yalnız PAH / CFTR · yalnız eğitim katı
5 **MODEL** — XGBoost × 3 seed · panel başına ayrı tarif
6 **EŞİK** — donmuş karar noktası · 0,595 – 0,780
7 **ÇIKTI** — kalibre olasılık · patojenik / benign

04 ÖZNİTELİK MÜHENDİSLİĞİ

351 ham kolon → 442 kolonluk temsil

91 türetilmiş öznitelik, altı aile — hepsi etiketten bağımsız.



- **46 öznitelik** amino asit değişiminin biyolojik şiddetini taşır: BLOSUM62/45/80, Grantham uzaklığı, 9 fizikokimyasal ölçek.
- Ham allel frekansları 10^{-3} – $2{,}6\times10^{5}$ aralığında; **log ölçeğe** alınır.
- **Eksiklik çift tepeli:** bir yanda yoğun anote edilmiş, diğer yanda iskelet varyantlar. Gürültü değil, bir **imza** — öznitelik olarak kodlanır.

05 ÖZNİTELİK SEÇİMİ

Şansa karşı duramayan öznitelik modele giremez.

441 aday, iki bağımsız istatistiksel filtre, panel başına 13–38 kolon.

PANEL	SEÇİM YÖNTEMİ	KALAN
GENEL	Hibrit (ReliefF-kapılı)	38
KANSER	Null-importance	35
PAH	Null-importance	37
CFTR	Null-importance	13

- **Filtre 1 · Null-importance.** Etiket permüte edilir, önem yeniden ölçülür; şans dağılımını geçemeyen elenir. Üç panelde tek başına yeterli.
- **Filtre 2 · ReliefF.** En yakın komşular üzerinden yerel ayrımı ölçer — global testin kaçırdığı sinyali yakalar.
- **Hibrit kapı.** Yalnızca GENEL'de: bir öznitelik iki testten *birden* geçerse kalır — en büyük ve en heterojen panel için ek güvence.
- **Sonuç:** modele giren her kolon, şansa karşı ayakta kalabildiğini **kanıtlamış** durumdadır — 441 adaydan panel başına 13–38'i.

06 CROSS-PANEL AUGMENTATION

Dış veri yoksa: sızıntısız ödünç satır.

GENEL'den, hedef panelde *hiç görünmeyen* varyantlar yalnızca eğitim katına eklenir. SMOTE değil: 442 boyutlu, %55 eksik bir uzayda sentetik profiller var olamaz.

PANEL	PANEL SATIRI	+ ÖDÜNÇ	ORAN
GENEL	2.931	–	0,00
KANSER	388	–	0,00
PAH	372	+2.676	1,00
CFTR	111	+2.854	1,00

ARTIRIM KAPALI **0,500** → ARTIRIM AÇIK **0,976** — CFTR ROC-AUC. 21 satırla ayrım öğrenilemiyor — artırım burada bir iyileştirme değil, **ön koşul**.

- **Neden sızıntı değil?** Ödünç satırlar tanım gereği hedef panelde yok; doğrulama her katta yalnızca panelin kendi satırlarıyla yapılır.
- **Meşruiyet:** paneller arasında ortak **578 varyantta etiketler %100 uyumlu** (GENEL∩PAH = 255, GENEL∩CFTR = 77).
- **KANSER dışarıda:** denendi, çok-seed bağımsız kontrolde kaybetti. Kural net — kazanırsa girer, kaybederse girmez.

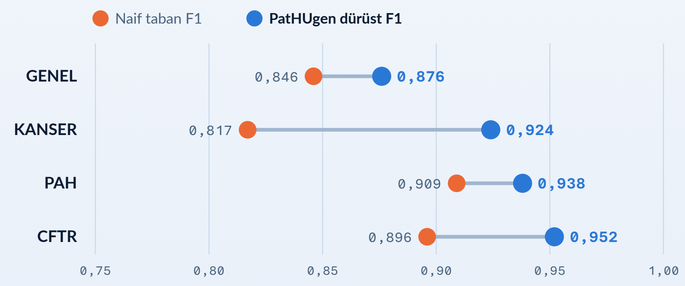
07 SONUÇLAR

Dürüst ölçüm, hiçbir ayarın bakmadığı sayıdadır.

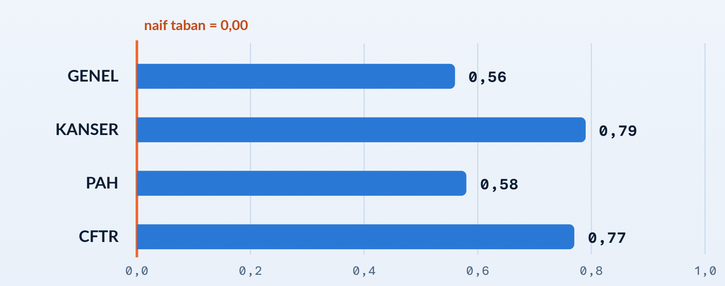
5 dış kat × 3 tekrar. Öznitelik listesi, hiperparametreler ve karar eşiği önceden kilitli — tek soru şu: modelin hiç görmediği satırlarda ne aldığı.

METRİK	GENEL	KANSER	PAH	CFTR
Varyant sayısı	2.931	388	372	111
Seçilen öznitelik	38	35	37	13
Dürüst F1 · 5×3 CV	**0,876**	**0,924**	**0,938**	**0,952**
Naif taban F1	0,846	0,817	0,909	0,896
Dürüst ROC-AUC	0,859	0,947	0,847	0,976
MCC · naif taban 0,00	**0,56**	**0,79**	**0,58**	**0,77**
Dengeli doğruluk · naif 0,50	0,79	0,89	0,72	0,90
Doğruluk	%82,1	%91,0	%89,8	%92,8
Duyarlılık / Özgüllük	0,86 / 0,71	0,94 / 0,85	0,99 / 0,45	0,94 / 0,86
Donmuş karar eşiği	0,670	0,705	0,595	0,780

Şekil 1 — Dürüst F1, naif tabana karşı. Naif taban zaten yüksek; kazanç birkaç puandır ve bunu saklamıyoruz.



Şekil 2 — Matthews korelasyon katsayısı (MCC). Naif tabanın MCC'si tam olarak 0,00 — gerçek katkı burada görünür.



Protokol
Tekrarlı tabakalı 5 katlı çapraz doğrulama, 3 tekrar (5×3). Cross-panel augmentation her katta yeniden uygulanır; doğrulama yalnızca panelin kendi satırlarıyla yapılır.

Ne kilitli?
Öznitelik listesi, hiperparametre paketi ve karar eşiği ölçümden önce dondurulur. Rapor edilen sayılar üretim modelinin kendisinden ölçülür; seed her yerde 42.

Açıkça söylediğimiz iki sınır
Hiperparametreler kat başına yeniden aranmaz — bu küçük bir iyimserlik payı bırakır. CFTR en yüksek skoru verir ama *n* = 111 ile en oynak paneldir.

08 HATA ANALİZİ

Hatalar bilinçli olarak tek yöne düşüyor.

PANEL	TN	FP	FN	TP	HATA
GENEL	559	223	301	1.848	%17,9
KANSER	102	18	17	251	%9,0
PAH	28	34	4	306	%10,2
CFTR	18	3	5	85	%7,2

- Karar eşiği **duyarlılığa eğimli** (0,86–0,99): yanlış negatif **kaçan tanı**, yanlış pozitif ise geri döndürülebilir bir ek test demektir. GENEL'deki 223 FP / 301 FN bu tercihin faturasıdır.
- **Öznitelik önemi:** GENEL ve KANSER'de en tepedeki sinyal *eksiklik imzası* (`missingtier_x_ekcount`); PAH ve CFTR'de allel/in-siliko ve evrimsel korunmuşluk öne çıkıyor.
- **Bunu başarı değil, risk olarak işaretliyoruz:** gerçek bir biyolojik sinyal de olabilir, veri toplama artefaktı da. Eksiklik grubu çıkarılmış F1 ayrıca ölçülecek.

09 KLİNİK ENTEGRASYON

Anotasyondan sonra, uzmandan önce — otonom tanı değil, triyaj.

SEKANSLAMA (laboratuvar) › ANOTASYON (lab'ın kendi çıktısı) › **PatHUgen (triyaj · panel paketi)** › UZMAN (ACMG kanıt tartımı) › RAPOR (hekim / danışman)

OTOMATİK BENİGN | UZMAN İNCELER — KARARSIZLIK DA BİR ÇIKTIDIR | OTOMATİK PATOJENİK

$p = 0$ — t_{alt} — $t_{üst}$ — $p = 1$

- **Veri sözleşmesi.** Giriş: laboratuvarın kendi anotasyon çıktısı — ek veritabanı, lisans ya da internet istemez. Çıkış: varyant tablosuna eklenen dört kolon (kalibre olasılık, bant, tarif sürümü, en katkılı 3 öznitelik grubu). Her satır hangi tarif ve eşikten geldiğini taşır; **denetim izi burada kurulur**.
- **Konuşlanma.** 6–58 µs/varyant, ~1 MB paket, tek CPU süreci, GPU yok, **sıfır dış çağrı** — genomik veri kurumdan çıkmaz. Farkımız kapsam değil, konuşlanma.
- **Emniyet sınırı.** ACMG kanıt kodu atamaz, VUS için sınıf iddia etmez, tanımadığı profili otomatik karara bağlamaz. Bant genişlikleri henüz elimizde yok — pilotun ilk çıktısı bu tablo.

Açıklık ve sınırlılıklar — sormadan söylüyoruz

TEKNOFEST verisi dışında hiçbir kaynak kullanılmadı; bu bir tercih değil, doğrulanabilir bir kısıt.

DIŞ VERİ YOK
ClinVar, gnomAD, dbNSFP sorgulanmadı; AlphaMissense, ESM1b, REVEL gibi hazır model çıktısı eklenmedi. **Kromozom ve pozisyon gizli, kolon adları anonim** — eşleştirme teknik olarak da imkânsız. Tek dış bilgi sabit tablolar: BLOSUM, Grantham, fizikokimyasal ölçekler.

ÖLÇEK VE DOĞRULAMA
3.802 varyant bir kavram kanıtıdır, klinik kanıt değil. Her laboratuvar kendi kohortunda doğrulamalıdır; ileriye dönük doğrulama ve kazanılan uzman saati ölçümü henüz yapılmadı.

PANEL KİMLİĞİ
CFTR satırlarının **~%96'sı GENEL'den ödünç** — bu saf bir CFTR modeli değil, GENEL → CFTR transferidir. PAH için de artırım oranı 1,00'dir.

VUS VE REGÜLASYON
Eğitim verimizde **VUS yok**; laboratuvarın en çok vakit kaybettiği yeri çözmüş gibi göstermiyoruz. Tanı yazılımı tıbbi cihaz kapsamındadır (TİTCK, IVDR/CE-IVD): kalite sistemi ve denetim izi şarttır.

"Bilimsiz pratik sağır, pratiksiz bilim kördür."
İBN-İ SİNA

Özgün katkımız yeni bir mimari değil, daha dürüst bir karar katmanıdır: sızıntısız cross-panel augmentation, adsız kolondan anlam çıkarımı, ReliefF kapılı hibrit seçici ve denetimden geçmiş sabit karar paketi — dördü de küçük kohortlu klinik tablo problemlerine taşınabilir.